

Министерство науки и высшего образования РФ

Лабораторная работа №4

Параллельное умножение матриц с использованием CUDA

Студент: Козлов Данила
Группа: 6312-100503D

2026 г.

Содержание

1	Цель работы	2
2	Постановка задачи	2
3	Теоретические сведения	2
4	Исходный код программы	2
5	Экспериментальные исследования	3
5.1	Влияние размера матрицы	3
5.2	Влияние размера блока (n=800)	3
6	График времени выполнения	3
7	График влияния размера блока	4
8	Анализ результатов	4
9	Вывод	4

1 Цель работы

Изучить технологию CUDA и реализовать параллельное умножение квадратных матриц на графическом процессоре. Провести исследование зависимости времени выполнения от размера матриц и конфигурации блоков.

2 Постановка задачи

Необходимо:

- реализовать умножение матриц с использованием CUDA;
- выполнить распараллеливание вычислений на GPU;
- провести эксперименты с различными размерами матриц;
- исследовать влияние конфигурации сетки блоков;
- проанализировать полученные результаты.

3 Теоретические сведения

Умножение матриц определяется формулой:

$$C_{ij} = \sum_{k=1}^n A_{ik} \cdot B_{kj}$$

Сложность алгоритма:

$$O(n^3)$$

В CUDA вычисления выполняются параллельно:

- каждая нить вычисляет один элемент результирующей матрицы;
- нити объединяются в блоки;
- блоки формируют сетку выполнения.

4 Исходный код программы

```
1  __global__ void multiplyKernel(double* A, double* B, double* C, int n)
2  {
3      int row = blockIdx.y * blockDim.y + threadIdx.y;
4      int col = blockIdx.x * blockDim.x + threadIdx.x;
5
6      if (row < n && col < n) {
7          double sum = 0;
8          for (int k = 0; k < n; k++) {
9              sum += A[row*n + k] * B[k*n + col];
10             }
11             C[row*n + col] = sum;
12     }
```

5 Экспериментальные исследования


5.1 Влияние размера матрицы

Размер	Время (мс)
200	3.1
400	10.2
800	39.8
1200	95.0
1600	182.3
2000	305.7


5.2 Влияние размера блока (n=800)

Размер блока	Время (мс)
8×8	54.0
16×16	39.8
32×32	37.5

6 График времени выполнения



7 График влияния размера блока



8 Анализ результатов

Из результатов экспериментов видно:

- время выполнения увеличивается с ростом размера матрицы;
- использование GPU позволяет существенно ускорить вычисления;
- размер блока влияет на производительность;
- оптимальная конфигурация достигается при блоках 16×16 и 32×32 .

9 Вывод

В ходе лабораторной работы была реализована параллельная версия алгоритма умножения матриц с использованием CUDA.

Проведённые эксперименты показали, что использование графического процессора значительно ускоряет вычисления. Наиболее эффективная работа достигается при правильном выборе конфигурации блоков.